

## Análisis por Componentes principales (PCA)

## Contenido

- PCA: Reducción de dimensionalidad de los datos.

## Contenido

- PCA: Reducción de dimensionalidad de los datos.
- SVD.

## Contenido

- PCA: Reducción de dimensionalidad de los datos.
- SVD.
- Componentes principales y varianza.

## Contenido

- PCA: Reducción de dimensionalidad de los datos.
- SVD.
- Componentes principales y varianza.
- Ejemplo.

## Contenido

- PCA: Reducción de dimensionalidad de los datos.
- SVD.
- Componentes principales y varianza.
- Ejemplo.

## Componentes principales

Matriz de  $m$  datos de  $n$  dimensiones:

$$\mathbf{A} = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix}$$

## Componentes principales

Matriz de  $m$  datos de  $n$  dimensiones:

$$\mathbf{A} = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix}$$

- Filas de  $\mathbf{A}$  son datos

$$\mathbf{x}_i^T = [x_{i1} \quad x_{i2} \quad \dots \quad x_{in}]$$



## Componentes principales

Matriz de  $m$  datos de  $n$  dimensiones:

$$\mathbf{A} = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix}$$


- Filas de  $\mathbf{A}$  son datos  
 $\mathbf{x}_i^T = [x_{i1} \quad x_{i2} \quad \dots \quad x_{in}]$
- Columnas de  $\mathbf{A}$  son descriptores (vectores en  $\mathbb{R}^m$ ).

## Componentes principales

Matriz de  $m$  datos de  $n$  dimensiones:

$$\mathbf{A} = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix}$$

- Filas de  $\mathbf{A}$  son datos  
 $\mathbf{x}_i^T = [x_{i1} \quad x_{i2} \quad \dots \quad x_{in}]$
- Columnas de  $\mathbf{A}$  son descriptores (vectores en  $\mathbb{R}^m$ ).




## Componentes principales

Matriz de  $m$  datos de  $n$  dimensiones:

$$\mathbf{A} = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix}$$

- Filas de  $\mathbf{A}$  son datos  
 $\mathbf{x}_i^T = [x_{i1} \quad x_{i2} \quad \dots \quad x_{in}]$
- Columnas de  $\mathbf{A}$  son descriptores (vectores en  $\mathbb{R}^m$ ).




- Preservar mayoría de la información en los datos en vector de dimensión menor.

## Componentes principales

Matriz de  $m$  datos de  $n$  dimensiones:

$$\mathbf{A} = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix}$$

- Filas de  $\mathbf{A}$  son datos  
 $\mathbf{x}_i^T = [x_{i1} \quad x_{i2} \quad \dots \quad x_{in}]$
- Columnas de  $\mathbf{A}$  son descriptores (vectores en  $\mathbb{R}^m$ ).



- Preservar mayoría de la información en los datos en vector de dimensión menor.
- Nuevos descriptores?

■ Centrar:

$$\mathbf{x}'_i = \mathbf{x}_i - \frac{1}{m} \sum_{j=1}^m \mathbf{x}_j$$

- Centrar:

$$\mathbf{x}'_i = \mathbf{x}_i - \frac{1}{m} \sum_{j=1}^m \mathbf{x}_j$$

- Matriz de covarianza:

$$\frac{1}{m} \mathbf{A}^T \mathbf{A} = \begin{bmatrix} \frac{1}{m} \sum_{j=1}^m x_{j1}^2 & \frac{1}{m} \sum_{j=1}^m x_{j1} x_{j2} & \cdots & \frac{1}{m} \sum_{j=1}^m x_{j1} x_{jn} \\ \frac{1}{m} \sum_{j=1}^m x_{j2} x_{j1} & \frac{1}{m} \sum_{j=1}^m x_{j2}^2 & \vdots & \\ \vdots & \vdots & \ddots & \\ \frac{1}{m} \sum_{j=1}^m x_{jn} x_{j1} & \cdots & & \frac{1}{m} \sum_{j=1}^m x_{jn}^2 \end{bmatrix}$$

Descomposición en valores singulares de  $\mathbf{A} \in \mathbb{R}^{m \times n}$

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$$

Descomposición en valores singulares de  $\mathbf{A} \in \mathbb{R}^{m \times n}$

$$\begin{aligned} \mathbf{A} &= \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T \\ &= \underbrace{\begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \dots & \mathbf{u}_r \end{bmatrix}}_{\text{base span de columnas}} \underbrace{\begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & \vdots \\ \vdots & 0 & \ddots & \\ 0 & \dots & & \sigma_r \end{bmatrix}}_{\text{valores singulares}} \underbrace{\begin{bmatrix} \mathbf{v}_1^T \\ \mathbf{v}_2^T \\ \vdots \\ \mathbf{v}_r^T \end{bmatrix}}_{\text{base span de filas}} \end{aligned}$$



Descomposición en valores singulares de  $\mathbf{A} \in \mathbb{R}^{m \times n}$

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$$
$$= \underbrace{\begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \dots & \mathbf{u}_r \end{bmatrix}}_{\text{base span de columnas}} \underbrace{\begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & \vdots \\ \vdots & 0 & \ddots & \\ 0 & \dots & & \sigma_r \end{bmatrix}}_{\text{valores singulares}} \underbrace{\begin{bmatrix} \mathbf{v}_1^T \\ \mathbf{v}_2^T \\ \vdots \\ \mathbf{v}_r^T \end{bmatrix}}_{\text{base span de filas}}$$

■  $\sigma_i = \sqrt{\lambda_i}$ , donde  $\lambda_i$  son los valores propios de  $\mathbf{A}^T \mathbf{A}$

## Descomposición en valores singulares de $\mathbf{A} \in \mathbb{R}^{m \times n}$

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$$
$$= \underbrace{\begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \dots & \mathbf{u}_r \end{bmatrix}}_{\text{base span de columnas}} \underbrace{\begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & \vdots \\ \vdots & 0 & \ddots & \\ 0 & \dots & & \sigma_r \end{bmatrix}}_{\text{valores singulares}} \underbrace{\begin{bmatrix} \mathbf{v}_1^T \\ \mathbf{v}_2^T \\ \vdots \\ \mathbf{v}_r^T \end{bmatrix}}_{\text{base span de filas}}$$

- $\sigma_i = \sqrt{\lambda_i}$ , donde  $\lambda_i$  son los valores propios de  $\mathbf{A}^T \mathbf{A}$
- $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$

- $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ : vectores propios de  $\mathbf{A}^T \mathbf{A}$ .


- $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ : vectores propios de  $\mathbf{A}^T \mathbf{A}$ .
- Un dato:

$$\mathbf{x}_i = \underbrace{(\mathbf{x}_i^T \mathbf{v}_1)}_{c_1} \mathbf{v}_1 + \underbrace{(\mathbf{x}_i^T \mathbf{v}_2)}_{c_2} \mathbf{v}_2 + \dots + \underbrace{(\mathbf{x}_i^T \mathbf{v}_r)}_{c_r} \mathbf{v}_r$$

■  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ : vectores propios de  $\mathbf{A}^T \mathbf{A}$ .

■ Un dato:


$$\mathbf{x}_i = \underbrace{(\mathbf{x}_i^T \mathbf{v}_1)}_{c_1} \mathbf{v}_1 + \underbrace{(\mathbf{x}_i^T \mathbf{v}_2)}_{c_2} \mathbf{v}_2 + \dots + \underbrace{(\mathbf{x}_i^T \mathbf{v}_r)}_{c_r} \mathbf{v}_r$$



■  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ : vectores propios de  $\mathbf{A}^T \mathbf{A}$ .

■ Un dato:

$$\mathbf{x}_i = \underbrace{(\mathbf{x}_i^T \mathbf{v}_1)}_{c_1} \mathbf{v}_1 + \underbrace{(\mathbf{x}_i^T \mathbf{v}_2)}_{c_2} \mathbf{v}_2 + \dots + \underbrace{(\mathbf{x}_i^T \mathbf{v}_r)}_{c_r} \mathbf{v}_r$$



- Primer componente principal:

$$\mathbf{Av}_1$$

- Primer componente principal:

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \mathbf{v}_1$$



- Primer componente principal:

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \mathbf{v}_1 \\ \mathbf{x}_2^T \mathbf{v}_1 \\ \vdots \\ \mathbf{x}_m^T \mathbf{v}_1 \end{bmatrix}$$

- Primer componente principal:

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \mathbf{v}_1 \\ \mathbf{x}_2^T \mathbf{v}_1 \\ \vdots \\ \mathbf{x}_m^T \mathbf{v}_1 \end{bmatrix} = \sigma_1 \mathbf{u}_1$$

- Primer componente principal:

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \mathbf{v}_1 \\ \mathbf{x}_2^T \mathbf{v}_1 \\ \vdots \\ \mathbf{x}_m^T \mathbf{v}_1 \end{bmatrix} = \sigma_1 \mathbf{u}_1 \longrightarrow \text{Varianza } \frac{1}{m} \|\sigma_1 \mathbf{u}_1\|^2$$

- Primer componente principal:

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \mathbf{v}_1 \\ \mathbf{x}_2^T \mathbf{v}_1 \\ \vdots \\ \mathbf{x}_m^T \mathbf{v}_1 \end{bmatrix} = \sigma_1 \mathbf{u}_1 \longrightarrow \text{Varianza } \frac{1}{m} \|\sigma_1 \mathbf{u}_1\|^2 = \frac{\sigma_1^2}{m}$$

- Primer componente principal:

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \mathbf{v}_1 \\ \mathbf{x}_2^T \mathbf{v}_1 \\ \vdots \\ \mathbf{x}_m^T \mathbf{v}_1 \end{bmatrix} = \sigma_1 \mathbf{u}_1 \longrightarrow \text{Varianza } \frac{1}{m} \|\sigma_1 \mathbf{u}_1\|^2 = \frac{\sigma_1^2}{m}$$

- Dos componentes principales:

- Primer componente principal:

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \mathbf{v}_1 \\ \mathbf{x}_2^T \mathbf{v}_1 \\ \vdots \\ \mathbf{x}_m^T \mathbf{v}_1 \end{bmatrix} = \sigma_1 \mathbf{u}_1 \longrightarrow \text{Varianza } \frac{1}{m} \|\sigma_1 \mathbf{u}_1\|^2 = \frac{\sigma_1^2}{m}$$

- Dos componentes principales:

$$\mathbf{A}\mathbf{v}_1 + \mathbf{A}\mathbf{v}_2$$

- Primer componente principal:

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \mathbf{v}_1 \\ \mathbf{x}_2^T \mathbf{v}_1 \\ \vdots \\ \mathbf{x}_m^T \mathbf{v}_1 \end{bmatrix} = \sigma_1 \mathbf{u}_1 \longrightarrow \text{Varianza } \frac{1}{m} \|\sigma_1 \mathbf{u}_1\|^2 = \frac{\sigma_1^2}{m}$$

- Dos componentes principales:

$$\mathbf{A}\mathbf{v}_1 + \mathbf{A}\mathbf{v}_2 = \sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2$$

- Primer componente principal:

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \mathbf{v}_1 \\ \mathbf{x}_2^T \mathbf{v}_1 \\ \vdots \\ \mathbf{x}_m^T \mathbf{v}_1 \end{bmatrix} = \sigma_1 \mathbf{u}_1 \longrightarrow \text{Varianza } \frac{1}{m} \|\sigma_1 \mathbf{u}_1\|^2 = \frac{\sigma_1^2}{m}$$

- Dos componentes principales:

$$\mathbf{A}\mathbf{v}_1 + \mathbf{A}\mathbf{v}_2 = \sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2 \longrightarrow \text{Varianza } \frac{1}{m} \|\sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2\|^2$$



- Primer componente principal:

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \mathbf{v}_1 \\ \mathbf{x}_2^T \mathbf{v}_1 \\ \vdots \\ \mathbf{x}_m^T \mathbf{v}_1 \end{bmatrix} = \sigma_1 \mathbf{u}_1 \longrightarrow \text{Varianza } \frac{1}{m} \|\sigma_1 \mathbf{u}_1\|^2 = \frac{\sigma_1^2}{m}$$

- Dos componentes principales:

$$\mathbf{A}\mathbf{v}_1 + \mathbf{A}\mathbf{v}_2 = \sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2 \longrightarrow \text{Varianza } \frac{1}{m} \|\sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2\|^2 = \frac{\sigma_1^2 + \sigma_2^2}{m}$$

- Primer componente principal:

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \mathbf{v}_1 \\ \mathbf{x}_2^T \mathbf{v}_1 \\ \vdots \\ \mathbf{x}_m^T \mathbf{v}_1 \end{bmatrix} = \sigma_1 \mathbf{u}_1 \longrightarrow \text{Varianza } \frac{1}{m} \|\sigma_1 \mathbf{u}_1\|^2 = \frac{\sigma_1^2}{m}$$

- Dos componentes principales:

$$\mathbf{A}\mathbf{v}_1 + \mathbf{A}\mathbf{v}_2 = \sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2 \longrightarrow \text{Varianza } \frac{1}{m} \|\sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2\|^2 = \frac{\sigma_1^2 + \sigma_2^2}{m}$$

- $k \leq n$  componentes principales:

$$\mathbf{A}\mathbf{v}_1 + \cdots + \mathbf{A}\mathbf{v}_k = \sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2 + \cdots + \sigma_k \mathbf{u}_k$$

- Primer componente principal:



$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \mathbf{v}_1 = \begin{bmatrix} \mathbf{x}_1^T \mathbf{v}_1 \\ \mathbf{x}_2^T \mathbf{v}_1 \\ \vdots \\ \mathbf{x}_m^T \mathbf{v}_1 \end{bmatrix} = \sigma_1 \mathbf{u}_1 \longrightarrow \text{Varianza } \frac{1}{m} \|\sigma_1 \mathbf{u}_1\|^2 = \frac{\sigma_1^2}{m}$$



- Dos componentes principales:


$$\mathbf{A}\mathbf{v}_1 + \mathbf{A}\mathbf{v}_2 = \sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2 \longrightarrow \text{Varianza } \frac{1}{m} \|\sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2\|^2 = \frac{\sigma_1^2 + \sigma_2^2}{m}$$


- $k \leq n$  componentes principales:


$$\mathbf{A}\mathbf{v}_1 + \cdots + \mathbf{A}\mathbf{v}_k = \sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2 + \cdots + \sigma_k \mathbf{u}_k \longrightarrow \text{Varianza } \frac{\sigma_1^2 + \sigma_2^2 + \cdots + \sigma_k^2}{m}$$













- En general,

$$\sigma_1, \sigma_2, \dots, \sigma_k \gg \sigma_{k+1}, \sigma_{k+2}, \dots, \sigma_r$$

- En general,

$$\sigma_1, \sigma_2, \dots, \sigma_k \gg \sigma_{k+1}, \sigma_{k+2}, \dots, \sigma_r$$

$$\Downarrow$$

$$\sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2 + \dots \sigma_k \mathbf{u}_k \approx \sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2 + \dots + \sigma_k \mathbf{u}_k + \sigma_{k+1} \mathbf{u}_{k+1} + \dots + \sigma_r \mathbf{u}_r$$

- En general,

$$\sigma_1, \sigma_2, \dots, \sigma_k \gg \sigma_{k+1}, \sigma_{k+2}, \dots, \sigma_r$$

$$\Downarrow$$

$$\sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2 + \dots + \sigma_k \mathbf{u}_k \approx \sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2 + \dots + \sigma_k \mathbf{u}_k + \sigma_{k+1} \mathbf{u}_{k+1} + \dots + \sigma_r \mathbf{u}_r$$

- Nueva matriz de datos:

$$\mathbf{Y} = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \underbrace{\begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_k \end{bmatrix}}_{\mathbf{V}_k}$$

- En general,

$$\sigma_1, \sigma_2, \dots, \sigma_k \gg \sigma_{k+1}, \sigma_{k+2}, \dots, \sigma_r$$

$$\Downarrow$$

$$\sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2 + \dots \sigma_k \mathbf{u}_k \approx \sigma_1 \mathbf{u}_1 + \sigma_2 \mathbf{u}_2 + \dots + \sigma_k \mathbf{u}_k + \sigma_{k+1} \mathbf{u}_{k+1} + \dots + \sigma_r \mathbf{u}_r$$

- Nueva matriz de datos:

$$\mathbf{Y} = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix} \underbrace{\begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_k \end{bmatrix}}_{\mathbf{V}_k} = \begin{bmatrix} \mathbf{x}_1^T \mathbf{v}_1 & \mathbf{x}_1^T \mathbf{v}_2 & \dots & \mathbf{x}_1^T \mathbf{v}_k \\ \mathbf{x}_2^T \mathbf{v}_1 & \mathbf{x}_2^T \mathbf{v}_2 & \dots & \mathbf{x}_2^T \mathbf{v}_k \\ \vdots & \vdots & \vdots & \vdots \\ \mathbf{x}_m^T \mathbf{v}_1 & \mathbf{x}_m^T \mathbf{v}_2 & \dots & \mathbf{x}_m^T \mathbf{v}_k \end{bmatrix}$$

# PCA

- 1 Centrar datos.

## PCA

- 1 Centrar datos.
- 2 Hallar valores propios de matriz  $\mathbf{A}^T \mathbf{A}$ :  $\sigma_1^2 \geq \sigma_2^2 \geq \dots \geq \sigma_n^2 > 0$ .

## PCA


- 1 Centrar datos.
- 2 Hallar valores propios de matriz  $\mathbf{A}^T \mathbf{A}$ :  $\sigma_1^2 \geq \sigma_2^2 \geq \dots \geq \sigma_n^2 > 0$ .
- 3 Escoger  $k$  que contenga porcentaje deseado de la varianza total.

## PCA

- 1 Centrar datos.
- 2 Hallar valores propios de matriz  $\mathbf{A}^T \mathbf{A}$ :  $\sigma_1^2 \geq \sigma_2^2 \geq \dots \geq \sigma_n^2 > 0$ .
- 3 Escoger  $k$  que contenga porcentaje deseado de la varianza total.
- 4 Calcular proyección de los datos  $\mathbf{y} = \mathbf{V}_k^T \mathbf{x}$




## Ejemplo MNIST




- Imágenes  $28 \times 28 = 784$  descriptores.
- 10000 imágenes.


## Ejemplo MNIST





- Imágenes  $28 \times 28 = 784$  descriptores.
- 10000 imágenes.



# Ejemplo MNIST



- Imágenes  $28 \times 28 = 784$  descriptores.
- 10000 imágenes.



## Resumen

- PCA: Datos  $\mathbf{A} \Rightarrow$  datos en menor dimensión  $\mathbf{Y} = \mathbf{A}\mathbf{V}_k$

## Resumen

- PCA: Datos  $\mathbf{A} \Rightarrow$  datos en menor dimensión  $\mathbf{Y} = \mathbf{AV}_k$
- Porcentaje de varianza explicada.

## Resumen

- PCA: Datos  $\mathbf{A} \Rightarrow$  datos en menor dimensión  $\mathbf{Y} = \mathbf{AV}_k$
- Porcentaje de varianza explicada.
- Típicamente podemos usar  $k \ll m$  componentes.