

Support Vector Machines


Fernando Lozano


Universidad de los Andes


10 de octubre de 2022



El perceptrón







Convergencia del Perceptrón

Teorema

Suponga:

Convergencia del Perceptrón

Teorema

Suponga:

- $\|\mathbf{x}_i\| \leq K \in \mathbb{R}, \quad i = 1 \dots, n.$

Convergencia del Perceptrón

Teorema

Suponga:

- $\|\mathbf{x}_i\| \leq K \in \mathbb{R}, \quad i = 1, \dots, n.$
- $\exists \hat{\mathbf{w}} \in \mathbb{R}^{d+1}, \delta > 0 \quad \text{tal que} \quad \hat{\mathbf{w}}^T \mathbf{x}_i \geq \delta \quad i = 1, \dots, n.$

Convergencia del Perceptrón

Teorema

Suponga:

- $\|\mathbf{x}_i\| \leq K \in \mathbb{R}, \quad i = 1, \dots, n.$
- $\exists \hat{\mathbf{w}} \in \mathbb{R}^{d+1}, \delta > 0 \quad \text{tal que} \quad \hat{\mathbf{w}}^T \mathbf{x}_i \geq \delta \quad i = 1, \dots, n.$

Entonces el algoritmo del perceptrón ejecuta el paso de actualización a lo sumo $\left(\frac{K\|\hat{\mathbf{w}}\|}{\delta}\right)^2$ veces.

Convergencia del Perceptrón

Teorema

Suponga:

- $\|\mathbf{x}_i\| \leq K \in \mathbb{R}, \quad i = 1, \dots, n.$
- $\exists \hat{\mathbf{w}} \in \mathbb{R}^{d+1}, \delta > 0 \quad \text{tal que} \quad \hat{\mathbf{w}}^T \mathbf{x}_i \geq \delta \quad i = 1, \dots, n.$

Entonces el algoritmo del perceptrón ejecuta el paso de actualización a lo sumo $\left(\frac{K\|\hat{\mathbf{w}}\|}{\delta}\right)^2$ veces.

- Deseable tener margen δ grande.

Convergencia del Perceptrón

Teorema

Suponga:


- $\|\mathbf{x}_i\| \leq K \in \mathbb{R}, \quad i = 1, \dots, n.$
- $\exists \hat{\mathbf{w}} \in \mathbb{R}^{d+1}, \delta > 0 \quad \text{tal que} \quad \hat{\mathbf{w}}^T \mathbf{x}_i \geq \delta \quad i = 1, \dots, n.$

Entonces el algoritmo del perceptrón ejecuta el paso de actualización a lo sumo $\left(\frac{K\|\hat{\mathbf{w}}\|}{\delta}\right)^2$ veces.

- Deseable tener margen δ grande.
- Algoritmo del perceptrón no tiene en cuenta el margen.


Motivación desde teoría de aprendizaje

- Structural Risk Minimization:



Motivación desde teoría de aprendizaje


- Structural Risk Minimization:



- Algoritmo de aprendizaje determina la complejidad apropiada de la clase de hipótesis.


Motivación desde teoría de aprendizaje

- Structural Risk Minimization:




- Algoritmo de aprendizaje determina la complejidad apropiada de la clase de hipótesis.
- Cómo variar **suavemente** la complejidad?


Clasificador con margen (caso linealmente separable)




Clasificador con margen (caso linealmente separable)



Clasificador con margen (caso linealmente separable)




Clasificador con margen (caso linealmente separable)





- **Márgen:** Distancia de un punto a la superficie de separación.

Clasificador con margen (caso linealmente separable)



- **Márgen**: Distancia de un punto a la superficie de separación.
- Es deseable tener **márgenes grandes**.

Margen grande vs. Complejidad



Cómo encontrar un separador lineal con margen grande?

Cómo encontrar un separador lineal con margen grande?

- Hipótesis $h(\mathbf{x}) = \text{sign}(\langle \mathbf{w}, \mathbf{x} \rangle + b)$

Cómo encontrar un separador lineal con margen grande?

- Hipótesis $h(\mathbf{x}) = \text{sign}(\langle \mathbf{w}, \mathbf{x} \rangle + b)$
- Separación:

Cómo encontrar un separador lineal con margen grande?

- Hipótesis $h(\mathbf{x}) = \text{sign}(\langle \mathbf{w}, \mathbf{x} \rangle + b)$
- Separación:

$$\begin{aligned} \langle \mathbf{w}, \mathbf{x}_i \rangle + b &\geq 1 && \text{Si } y_i = 1 \\ \langle \mathbf{w}, \mathbf{x}_i \rangle + b &\leq -1 && \text{Si } y_i = -1 \end{aligned}$$

Cómo encontrar un separador lineal con margen grande?

- Hipótesis $h(\mathbf{x}) = \text{sign}(\langle \mathbf{w}, \mathbf{x} \rangle + b)$
- Separación:


$$\left. \begin{array}{ll} \langle \mathbf{w}, \mathbf{x}_i \rangle + b \geq 1 & \text{Si } y_i = 1 \\ \langle \mathbf{w}, \mathbf{x}_i \rangle + b \leq -1 & \text{Si } y_i = -1 \end{array} \right\} y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad \forall i$$


Cómo encontrar un separador lineal con margen grande?


- Hipótesis $h(\mathbf{x}) = \text{sign}(\langle \mathbf{w}, \mathbf{x} \rangle + b)$
- Separación:


$$\left. \begin{array}{ll} \langle \mathbf{w}, \mathbf{x}_i \rangle + b \geq 1 & \text{Si } y_i = 1 \\ \langle \mathbf{w}, \mathbf{x}_i \rangle + b \leq -1 & \text{Si } y_i = -1 \end{array} \right\} y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad \forall i$$


- **Márgen?**

















- Problema de optimización:

$$\begin{array}{ll} \text{mín} & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{sujeto a} & y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n \end{array}$$

- Problema de optimización:

$$\begin{aligned} & \text{mín} \quad \frac{1}{2} \|\mathbf{w}\|^2 \\ & \text{sujeto a} \quad y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n \end{aligned}$$

- Problema de programación cuadrática.

- Problema de optimización:

$$\begin{aligned} & \text{mín} \quad \frac{1}{2} \|\mathbf{w}\|^2 \\ & \text{sujeto a} \quad y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n \end{aligned}$$

- Problema de programación cuadrática.
- Problema convexo:

- Problema de optimización:

$$\begin{aligned} \text{mín} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{sujeto a} \quad & y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n \end{aligned}$$

- Problema de **programación cuadrática**.
- Problema **convexo**:
 - ▶ Único mínimo global.

- Problema de optimización:

$$\begin{aligned} \text{mín} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{sujeto a} \quad & y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n \end{aligned}$$

- Problema de **programación cuadrática**.
- Problema **convexo**:
 - ▶ Único mínimo global.
 - ▶ Condiciones de Karush-Kuhn-Tucker (KKT) son suficientes y necesarias para **mínimo global y máximo global del problema dual**.

- Problema de optimización:

$$\begin{aligned} & \text{mín} \quad \frac{1}{2} \|\mathbf{w}\|^2 \\ & \text{sujeto a} \quad y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n \end{aligned}$$

- Problema de **programación cuadrática**.
- Problema **convexo**:
 - ▶ Único mínimo global.
 - ▶ Condiciones de Karush-Kuhn-Tucker (KKT) son suficientes y necesarias para **mínimo global y máximo global del problema dual**.
 - ▶ Solución eficiente.

- Problema de optimización:

$$\begin{aligned} & \text{mín} \quad \frac{1}{2} \|\mathbf{w}\|^2 \\ & \text{sujeito a} \quad y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n \end{aligned}$$

- Problema de **programación cuadrática**.
- Problema **convexo**:
 - ▶ Único mínimo global.
 - ▶ Condiciones de Karush-Kuhn-Tucker (KKT) son suficientes y necesarias para **mínimo global y máximo global del problema dual**.
 - ▶ Solución eficiente.
 - ▶ Tamaño puede ser grande.

Problema dual

Problema dual

- Introducimos multiplicadores de Lagrange

$$\boldsymbol{\alpha} = [\alpha_1, \alpha_2, \dots, \alpha_n] \geq 0.$$

Problema dual

- Introducimos multiplicadores de Lagrange $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_n] \geq 0$. El **Lagrangiano**:

Problema dual

- Introducimos multiplicadores de Lagrange

$\boldsymbol{\alpha} = [\alpha_1, \alpha_2, \dots, \alpha_n] \geq 0$. El **Lagrangiano**:

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1)$$

Problema dual

- Introducimos multiplicadores de Lagrange

$\alpha = [\alpha_1, \alpha_2, \dots, \alpha_n] \geq 0$. El **Lagrangiano**:

$$\begin{aligned} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1) \\ &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) + \sum_{i=1}^n \alpha_i \end{aligned}$$

Problema dual

- Introducimos multiplicadores de Lagrange

$\boldsymbol{\alpha} = [\alpha_1, \alpha_2, \dots, \alpha_n] \geq 0$. El **Lagrangiano**:

$$\begin{aligned} L(\mathbf{w}, b, \boldsymbol{\alpha}) &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1) \\ &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) + \sum_{i=1}^n \alpha_i \end{aligned}$$

- Minimizamos $L(\mathbf{w}, b, \boldsymbol{\alpha})$ con respecto a \mathbf{w}, b para obtener la **función dual**:

Problema dual

- Introducimos multiplicadores de Lagrange

$\alpha = [\alpha_1, \alpha_2, \dots, \alpha_n] \geq 0$. El **Lagrangiano**:

$$\begin{aligned} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1) \\ &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) + \sum_{i=1}^n \alpha_i \end{aligned}$$

- Minimizamos $L(\mathbf{w}, b, \alpha)$ con respecto a \mathbf{w}, b para obtener la **función dual**:

$$\frac{\partial L}{\partial b} = 0$$

Problema dual

- Introducimos multiplicadores de Lagrange

$\alpha = [\alpha_1, \alpha_2, \dots, \alpha_n] \geq 0$. El **Lagrangiano**:

$$\begin{aligned} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1) \\ &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) + \sum_{i=1}^n \alpha_i \end{aligned}$$

- Minimizamos $L(\mathbf{w}, b, \alpha)$ con respecto a \mathbf{w}, b para obtener la **función dual**:

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

Problema dual

- Introducimos multiplicadores de Lagrange

$\boldsymbol{\alpha} = [\alpha_1, \alpha_2, \dots, \alpha_n] \geq 0$. El **Lagrangiano**:

$$\begin{aligned} L(\mathbf{w}, b, \boldsymbol{\alpha}) &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1) \\ &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) + \sum_{i=1}^n \alpha_i \end{aligned}$$

- Minimizamos $L(\mathbf{w}, b, \boldsymbol{\alpha})$ con respecto a \mathbf{w}, b para obtener la **función dual**:

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \mathbf{w}} = 0$$

Problema dual

- Introducimos multiplicadores de Lagrange

$\alpha = [\alpha_1, \alpha_2, \dots, \alpha_n] \geq 0$. El **Lagrangiano**:

$$\begin{aligned} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1) \\ &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) + \sum_{i=1}^n \alpha_i \end{aligned}$$

- Minimizamos $L(\mathbf{w}, b, \alpha)$ con respecto a \mathbf{w}, b para obtener la **función dual**:

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$$

- Reemplazando en el Lagrangiano:

- Reemplazando en el Lagrangiano:

$$L = \frac{1}{2} \left\langle \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i, \sum_{j=1}^n (\alpha_j y_j) \mathbf{x}_j \right\rangle \\ - \sum_{i=1}^n \alpha_i y_i \left(\left\langle \sum_{j=1}^n (\alpha_j y_j) \mathbf{x}_j, \mathbf{x}_i \right\rangle + b \right) + \sum_{i=1}^n \alpha_i$$

- Reemplazando en el Lagrangiano:

$$L = \frac{1}{2} \left\langle \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i, \sum_{j=1}^n (\alpha_j y_j) \mathbf{x}_j \right\rangle - \sum_{i=1}^n \alpha_i y_i \left(\left\langle \sum_{j=1}^n (\alpha_j y_j) \mathbf{x}_j, \mathbf{x}_i \right\rangle + b \right) + \sum_{i=1}^n \alpha_i$$

- Obtenemos la **función dual**:

$$g(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle$$

- Reemplazando en el Lagrangiano:

$$L = \frac{1}{2} \left\langle \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i, \sum_{j=1}^n (\alpha_j y_j) \mathbf{x}_j \right\rangle - \sum_{i=1}^n \alpha_i y_i \left(\left\langle \sum_{j=1}^n (\alpha_j y_j) \mathbf{x}_j, \mathbf{x}_i \right\rangle + b \right) + \sum_{i=1}^n \alpha_i$$

- Obtenemos la **función dual**:

$$g(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle = \mathbf{1}^T \boldsymbol{\alpha} - \frac{1}{2} \boldsymbol{\alpha}^T \bar{\mathbf{K}} \boldsymbol{\alpha}$$

donde $[\bar{\mathbf{K}}]_{ij} = y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle$

Problema Dual

$$\begin{aligned} & \text{máx} && \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \\ & \text{sujeto a} && \sum_{i=1}^n \alpha_i y_i = 0 \\ & && \boldsymbol{\alpha} \geq 0 \end{aligned}$$

Problema Dual

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \\ \text{sujeto a} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & \boldsymbol{\alpha} \geq 0 \end{aligned}$$

- Problema de programación cuadrática **cóncavo**.

Problema Dual

$$\begin{aligned} & \text{máx} && \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \\ & \text{sujeto a} && \sum_{i=1}^n \alpha_i y_i = 0 \\ & && \boldsymbol{\alpha} \geq 0 \end{aligned}$$

- Problema de programación cuadrática **cóncavo**.
- Los datos \mathbf{x}_i sólo aparecen en productos punto.

Condiciones de Karush-Kuhn-Tucker (KKT)

Condiciones de Karush-Kuhn-Tucker (KKT)

$$\textcircled{1} \quad y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n$$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ❶ $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n$
- ❷ $\alpha_i \geq 0 \quad i = 1, \dots, n$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ❶ $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n$
- ❷ $\alpha_i \geq 0 \quad i = 1, \dots, n$
- ❸ $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ① $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n$
- ② $\alpha_i \geq 0 \quad i = 1, \dots, n$
- ③ $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$
- ④ $\sum_{i=1}^n \alpha_i y_i = 0$

Condiciones de Karush-Kuhn-Tucker (KKT)

$$\textcircled{1} \quad y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n$$

$$\textcircled{2} \quad \alpha_i \geq 0 \quad i = 1, \dots, n$$

$$\textcircled{3} \quad \mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$$

$$\textcircled{4} \quad \sum_{i=1}^n \alpha_i y_i = 0$$

$$\textcircled{5} \quad \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1) = 0$$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ❶ $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n$
- ❷ $\alpha_i \geq 0 \quad i = 1, \dots, n$
- ❸ $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$
- ❹ $\sum_{i=1}^n \alpha_i y_i = 0$
- ❺ $\alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1) = 0$
- Las condiciones 3 y 5 implican que la suma $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$ sólo involucra vectores \mathbf{x}_i para los cuales la restricción es **activa**.

Condiciones de Karush-Kuhn-Tucker (KKT)

$$\textcircled{1} \quad y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n$$

$$\textcircled{2} \quad \alpha_i \geq 0 \quad i = 1, \dots, n$$

$$\textcircled{3} \quad \mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$$

$$\textcircled{4} \quad \sum_{i=1}^n \alpha_i y_i = 0$$

$$\textcircled{5} \quad \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1) = 0$$

- Las condiciones 3 y 5 implican que la suma $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$ sólo involucra vectores \mathbf{x}_i para los cuales la restricción es **activa**.
- Estos vectores se llaman **vectores de soporte**.

Condiciones de Karush-Kuhn-Tucker (KKT)

$$\textcircled{1} \quad y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad i = 1, \dots, n$$

$$\textcircled{2} \quad \alpha_i \geq 0 \quad i = 1, \dots, n$$


$$\textcircled{3} \quad \mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$$


$$\textcircled{4} \quad \sum_{i=1}^n \alpha_i y_i = 0$$

$$\textcircled{5} \quad \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1) = 0$$

- Las condiciones 3 y 5 implican que la suma $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$ sólo involucra vectores \mathbf{x}_i para los cuales la restricción es **activa**.
- Estos vectores se llaman **vectores de soporte**.
- Si S es el conjunto de vectores de soporte tenemos:

$$\mathbf{w} = \sum_{i: \mathbf{x}_i \in S} (\alpha_i y_i) \mathbf{x}_i$$





Caso no separable

- En general, puede no existir una solución con error cero en los datos.

Caso no separable

- En general, puede no existir una solución con error cero en los datos.
- Se introducen **variables de holgura** $\zeta_1, \zeta_2, \dots, \zeta_n \geq 0$:

Caso no separable

- En general, puede no existir una solución con error cero en los datos.
- Se introducen **variables de holgura** $\zeta_1, \zeta_2, \dots, \zeta_n \geq 0$:

$$\begin{aligned} \langle \mathbf{w}, \mathbf{x}_i \rangle + b &\geq 1 - \zeta_i && \text{Si } y_i = 1 \\ \langle \mathbf{w}, \mathbf{x}_i \rangle + b &\leq -1 + \zeta_i && \text{Si } y_i = -1 \end{aligned}$$

Caso no separable

- En general, puede no existir una solución con error cero en los datos.
- Se introducen **variables de holgura** $\zeta_1, \zeta_2, \dots, \zeta_n \geq 0$:

$$\left. \begin{array}{ll} \langle \mathbf{w}, \mathbf{x}_i \rangle + b \geq 1 - \zeta_i & \text{Si } y_i = 1 \\ \langle \mathbf{w}, \mathbf{x}_i \rangle + b \leq -1 + \zeta_i & \text{Si } y_i = -1 \end{array} \right\} y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad \forall i$$

Caso no separable

- En general, puede no existir una solución con error cero en los datos.
- Se introducen **variables de holgura** $\zeta_1, \zeta_2, \dots, \zeta_n \geq 0$:

$$\left. \begin{array}{ll} \langle \mathbf{w}, \mathbf{x}_i \rangle + b \geq 1 - \zeta_i & \text{Si } y_i = 1 \\ \langle \mathbf{w}, \mathbf{x}_i \rangle + b \leq -1 + \zeta_i & \text{Si } y_i = -1 \end{array} \right\} y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad \forall i$$

- ▶ Si hay error en \mathbf{x}_i

Caso no separable

- En general, puede no existir una solución con error cero en los datos.
- Se introducen **variables de holgura** $\zeta_1, \zeta_2, \dots, \zeta_n \geq 0$:

$$\left. \begin{array}{ll} \langle \mathbf{w}, \mathbf{x}_i \rangle + b \geq 1 - \zeta_i & \text{Si } y_i = 1 \\ \langle \mathbf{w}, \mathbf{x}_i \rangle + b \leq -1 + \zeta_i & \text{Si } y_i = -1 \end{array} \right\} y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad \forall i$$

- ▶ Si hay error en $\mathbf{x}_i \Rightarrow \zeta_i > 0$.

Caso no separable

- En general, puede no existir una solución con error cero en los datos.
- Se introducen **variables de holgura** $\zeta_1, \zeta_2, \dots, \zeta_n \geq 0$:

$$\left. \begin{array}{ll} \langle \mathbf{w}, \mathbf{x}_i \rangle + b \geq 1 - \zeta_i & \text{Si } y_i = 1 \\ \langle \mathbf{w}, \mathbf{x}_i \rangle + b \leq -1 + \zeta_i & \text{Si } y_i = -1 \end{array} \right\} y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad \forall i$$

- ▶ Si hay error en $\mathbf{x}_i \Rightarrow \zeta_i > 1$.
- ▶ Luego $\sum_{i=1}^n \zeta_i$ es una **cota superior** del número de errores.

Problema de optimización

$$\begin{aligned} \text{mín} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \zeta_i \\ \text{sujeto a} \quad & y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n \\ & \zeta_i \geq 0 \end{aligned}$$

Problema de optimización

$$\begin{aligned} \text{mín} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \zeta_i \\ \text{sujeto a} \quad & y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n \\ & \zeta_i \geq 0 \end{aligned}$$

- C es un parámetro que indica el balance deseado entre margen y error.

Problema de optimización

$$\begin{aligned} \text{mín} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \zeta_i \\ \text{sujeto a} \quad & y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n \\ & \zeta_i \geq 0 \end{aligned}$$

- C es un parámetro que indica el balance deseado entre margen y error.

Problema Dual

$$L(\mathbf{w}, b, \zeta, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + \textcolor{red}{C} \sum_{i=1}^n \zeta_i - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) - \sum_{i=1}^n \mu_i \zeta_i$$

Problema Dual

$$L(\mathbf{w}, b, \zeta, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + \textcolor{red}{C} \sum_{i=1}^n \zeta_i \\ - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) - \sum_{i=1}^n \mu_i \zeta_i$$

Derivando con respecto a las variables primales:

Problema Dual

$$L(\mathbf{w}, b, \zeta, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + \textcolor{red}{C} \sum_{i=1}^n \zeta_i \\ - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) - \sum_{i=1}^n \mu_i \zeta_i$$

Derivando con respecto a las variables primales:

$$\frac{\partial L}{\partial b} = 0$$

Problema Dual

$$L(\mathbf{w}, b, \zeta, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + \textcolor{red}{C} \sum_{i=1}^n \zeta_i \\ - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) - \sum_{i=1}^n \mu_i \zeta_i$$

Derivando con respecto a las variables primales:

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

Problema Dual

$$L(\mathbf{w}, b, \zeta, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + \textcolor{red}{C} \sum_{i=1}^n \zeta_i \\ - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) - \sum_{i=1}^n \mu_i \zeta_i$$

Derivando con respecto a las variables primales:

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \mathbf{w}} = 0$$

Problema Dual

$$L(\mathbf{w}, b, \zeta, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + \textcolor{red}{C} \sum_{i=1}^n \zeta_i \\ - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) - \sum_{i=1}^n \mu_i \zeta_i$$

Derivando con respecto a las variables primales:

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$$

Problema Dual

$$L(\mathbf{w}, b, \zeta, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \zeta_i - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) - \sum_{i=1}^n \mu_i \zeta_i$$

Derivando con respecto a las variables primales:

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$$

$$\frac{\partial L}{\partial \zeta_i} = 0$$

Problema Dual

$$L(\mathbf{w}, b, \zeta, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \zeta_i - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) - \sum_{i=1}^n \mu_i \zeta_i$$

Derivando con respecto a las variables primales:

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$$

$$\frac{\partial L}{\partial \zeta_i} = 0 \Rightarrow \alpha_i + \mu_i = C$$

Problema Dual

$$L(\mathbf{w}, b, \zeta, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \zeta_i - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) - \sum_{i=1}^n \mu_i \zeta_i$$

Derivando con respecto a las variables primales:

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$$

$$\frac{\partial L}{\partial \zeta_i} = 0 \Rightarrow \alpha_i + \mu_i = C \Rightarrow \alpha_i \leq C$$

$$L = \frac{1}{2} \left\langle \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i, \sum_{j=1}^n (\alpha_j y_j) \mathbf{x}_j \right\rangle + \textcolor{red}{C} \sum_{i=1}^n \zeta_i$$

$$- \sum_{i=1}^n \alpha_i \left(y_i \left(\left\langle \sum_{j=1}^n (\alpha_j y_j) \mathbf{x}_j, \mathbf{x}_i \right\rangle + b \right) - 1 + \zeta_i \right) - \sum_{i=1}^n \mu_i \zeta_i$$

$$L = \frac{1}{2} \left\langle \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i, \sum_{j=1}^n (\alpha_j y_j) \mathbf{x}_j \right\rangle + \textcolor{red}{C} \sum_{i=1}^n \zeta_i \\ - \sum_{i=1}^n \alpha_i \left(y_i \left(\left\langle \sum_{j=1}^n (\alpha_j y_j) \mathbf{x}_j, \mathbf{x}_i \right\rangle + b \right) - 1 + \zeta_i \right) - \sum_{i=1}^n \mu_i \zeta_i$$

Obtenemos la **misma función dual**:

$$g(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle$$

$$L = \frac{1}{2} \left\langle \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i, \sum_{j=1}^n (\alpha_j y_j) \mathbf{x}_j \right\rangle + \textcolor{red}{C} \sum_{i=1}^n \zeta_i$$

$$- \sum_{i=1}^n \alpha_i \left(y_i \left(\left\langle \sum_{j=1}^n (\alpha_j y_j) \mathbf{x}_j, \mathbf{x}_i \right\rangle + b \right) - 1 + \zeta_i \right) - \sum_{i=1}^n \mu_i \zeta_i$$

Obtenemos la **misma función dual**:

$$g(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle = \mathbf{1}^T \boldsymbol{\alpha} - \frac{1}{2} \boldsymbol{\alpha}^T \bar{\mathbf{K}} \boldsymbol{\alpha}$$

donde $[\bar{\mathbf{K}}]_{ij} = y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle$

Problema dual

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \\ \text{sujeto a} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C \end{aligned}$$

Problema dual

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \\ \text{sujeto a} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C \end{aligned}$$

- Unico cambio en el dual es cota superior en los multiplicadores α_i .

Condiciones de Karush-Kuhn-Tucker (KKT)

$$\textcircled{1} \quad y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ❶ $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$
- ❷ $\zeta_i \geq 0$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ❶ $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$
- ❷ $\zeta_i \geq 0$
- ❸ $\mu_i \geq 0$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ❶ $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$
- ❷ $\zeta_i \geq 0$
- ❸ $\mu_i \geq 0$
- ❹ $\alpha_i + \mu_i = C$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ① $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$
- ② $\zeta_i \geq 0$
- ③ $\mu_i \geq 0$
- ④ $\alpha_i + \mu_i = C$
- ⑤ $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ① $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$
- ② $\zeta_i \geq 0$
- ③ $\mu_i \geq 0$
- ④ $\alpha_i + \mu_i = C$
- ⑤ $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$
- ⑥ $\sum_{i=1}^n \alpha_i y_i = 0$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ① $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$
- ② $\zeta_i \geq 0$
- ③ $\mu_i \geq 0$
- ④ $\alpha_i + \mu_i = C$
- ⑤ $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$
- ⑥ $\sum_{i=1}^n \alpha_i y_i = 0$
- ⑦ $\alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) = 0$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ❶ $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$
- ❷ $\zeta_i \geq 0$
- ❸ $\mu_i \geq 0$
- ❹ $\alpha_i + \mu_i = C$
- ❺ $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$
- ❻ $\sum_{i=1}^n \alpha_i y_i = 0$
- ❼ $\alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) = 0$
- ❽ $\zeta_i \mu_i = 0$

Condiciones de Karush-Kuhn-Tucker (KKT)

$$\textcircled{1} \quad y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$$

$$\textcircled{2} \quad \zeta_i \geq 0$$

$$\textcircled{3} \quad \mu_i \geq 0$$

$$\textcircled{4} \quad \alpha_i + \mu_i = C$$

$$\textcircled{5} \quad \mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$$

$$\textcircled{6} \quad \sum_{i=1}^n \alpha_i y_i = 0$$

$$\textcircled{7} \quad \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) = 0$$

$$\textcircled{8} \quad \zeta_i \mu_i = 0$$

$$\alpha_i = C$$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ❶ $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$
- ❷ $\zeta_i \geq 0$
- ❸ $\mu_i \geq 0$
- ❹ $\alpha_i + \mu_i = C$
- ❺ $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$
- ❻ $\sum_{i=1}^n \alpha_i y_i = 0$
- ❼ $\alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) = 0$
- ❽ $\zeta_i \mu_i = 0$

$$\alpha_i = C \Rightarrow \mu_i = 0$$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ❶ $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$
- ❷ $\zeta_i \geq 0$
- ❸ $\mu_i \geq 0$
- ❹ $\alpha_i + \mu_i = C$
- ❺ $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$
- ❻ $\sum_{i=1}^n \alpha_i y_i = 0$
- ❼ $\alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) = 0$
- ❽ $\zeta_i \mu_i = 0$

$$\alpha_i = C \Rightarrow \mu_i = 0 \Rightarrow \zeta_i \geq 0,$$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ❶ $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$
- ❷ $\zeta_i \geq 0$
- ❸ $\mu_i \geq 0$
- ❹ $\alpha_i + \mu_i = C$
- ❺ $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$
- ❻ $\sum_{i=1}^n \alpha_i y_i = 0$
- ❼ $\alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) = 0$
- ❽ $\zeta_i \mu_i = 0$


$$\alpha_i = C \Rightarrow \mu_i = 0 \Rightarrow \zeta_i \geq 0, \quad y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 1 - \zeta_i$$

Condiciones de Karush-Kuhn-Tucker (KKT)

- ❶ $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$
- ❷ $\zeta_i \geq 0$
- ❸ $\mu_i \geq 0$
- ❹ $\alpha_i + \mu_i = C$
- ❺ $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \mathbf{x}_i$
- ❻ $\sum_{i=1}^n \alpha_i y_i = 0$
- ❼ $\alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i) = 0$
- ❽ $\zeta_i \mu_i = 0$

$$\alpha_i = C \Rightarrow \mu_i = 0 \Rightarrow \zeta_i \geq 0, \quad y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 1 - \zeta_i$$

- Ahora los vectores de soporte incluyen vectores en los que **hay error de margen** o hay **error de clasificación**.



Formulación equivalente

Formulación equivalente

- Sea $f(\mathbf{x}_i) = \langle \mathbf{w}, \mathbf{x}_i \rangle + b$,

Formulación equivalente

- Sea $f(\mathbf{x}_i) = \langle \mathbf{w}, \mathbf{x}_i \rangle + b$, $m_i = y_i f(\mathbf{x}_i)$ es el **margen de clasificación**.

Formulación equivalente

- Sea $f(\mathbf{x}_i) = \langle \mathbf{w}, \mathbf{x}_i \rangle + b$, $m_i = y_i f(\mathbf{x}_i)$ es el **margen de clasificación**.
- Función de **costo** del margen:

$$l(m) = \begin{cases} 1 - m & m \leq 1 \\ 0 & m > 1 \end{cases}$$

Formulación equivalente


- Sea $f(\mathbf{x}_i) = \langle \mathbf{w}, \mathbf{x}_i \rangle + b$, $m_i = y_i f(\mathbf{x}_i)$ es el **margen de clasificación**.
- Función de **costo** del margen:

$$l(m) = \begin{cases} 1 - m & m \leq 1 \\ 0 & m > 1 \end{cases} = \max \{1 - m, 0\}$$

Formulación equivalente

- Sea $f(\mathbf{x}_i) = \langle \mathbf{w}, \mathbf{x}_i \rangle + b$, $m_i = y_i f(\mathbf{x}_i)$ es el **margen de clasificación**.
- Función de **costo** del margen:

$$l(m) = \begin{cases} 1 - m & m \leq 1 \\ 0 & m > 1 \end{cases} = \max \{1 - m, 0\}$$



$$\min_{\mathbf{w}} \quad l(\mathbf{w}) + \frac{1}{2C} \|\mathbf{w}\|^2$$

$$\min_{\mathbf{w}} \quad l(\mathbf{w}) + \frac{1}{2C} \|\mathbf{w}\|^2$$

- $l(\mathbf{w})$ función de error **convexa**.

$$\min_{\mathbf{w}} \quad l(\mathbf{w}) + \frac{1}{2C} \|\mathbf{w}\|^2$$

- $l(\mathbf{w})$ función de error **convexa**.
- $\|\mathbf{w}\|^2$: regularización.

$$\min_{\mathbf{w}} \quad l(\mathbf{w}) + \frac{1}{2C} \|\mathbf{w}\|^2$$

- $l(\mathbf{w})$ función de error **convexa**.
- $\|\mathbf{w}\|^2$: regularización.
- $\frac{1}{2C}$: constante de regularización.

Caso no lineal

Caso no lineal

- **Idea:** Proyectar datos a un espacio donde sean más fácilmente separables.

Caso no lineal

- **Idea:** Proyectar datos a un espacio donde sean más fácilmente separables.

$$\mathcal{X} \rightarrow \mathcal{H}$$

$$\mathbf{x} \mapsto \phi(\mathbf{x})$$

Caso no lineal

- **Idea:** Proyectar datos a un espacio donde sean más fácilmente separables.

$$\mathcal{X} \rightarrow \mathcal{H}$$

$$\mathbf{x} \mapsto \phi(\mathbf{x})$$

Donde \mathcal{H} es un espacio de **Hilbert**:

Caso no lineal

- **Idea:** Proyectar datos a un espacio donde sean más fácilmente separables.

$$\mathcal{X} \rightarrow \mathcal{H}$$

$$\mathbf{x} \mapsto \phi(\mathbf{x})$$

Donde \mathcal{H} es un espacio de **Hilbert**:

- ▶ Producto punto.

Caso no lineal

- **Idea:** Proyectar datos a un espacio donde sean más fácilmente separables.

$$\mathcal{X} \rightarrow \mathcal{H}$$

$$\mathbf{x} \mapsto \phi(\mathbf{x})$$

Donde \mathcal{H} es un espacio de **Hilbert**:

- ▶ Producto punto.
- ▶ Completo.

Caso no lineal

- **Idea:** Proyectar datos a un espacio donde sean más fácilmente separables.

$$\begin{aligned}\mathcal{X} &\rightarrow \mathcal{H} \\ \mathbf{x} &\mapsto \phi(\mathbf{x})\end{aligned}$$

Donde \mathcal{H} es un espacio de **Hilbert**:

- ▶ Producto punto.
- ▶ Completo.
- Operamos en el **espacio de características** \mathcal{H} :

$$\langle \mathbf{x}_i, \mathbf{x}_j \rangle \longrightarrow \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle_{\mathcal{H}}$$

Caso no lineal

- **Idea:** Proyectar datos a un espacio donde sean más fácilmente separables.

$$\begin{aligned}\mathcal{X} &\rightarrow \mathcal{H} \\ \mathbf{x} &\mapsto \phi(\mathbf{x})\end{aligned}$$

Donde \mathcal{H} es un espacio de **Hilbert**:

- ▶ Producto punto.
- ▶ Completo.
- Operamos en el **espacio de características** \mathcal{H} :

$$\langle \mathbf{x}_i, \mathbf{x}_j \rangle \longrightarrow \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle_{\mathcal{H}}$$

- \mathcal{X} puede ser un conjunto arbitrario.

Problema de optimización

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \\ \text{sujeto a} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C \end{aligned}$$

Problema de optimización

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle_{\mathcal{H}} \\ \text{sujeto a} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C \end{aligned}$$

Problema de optimización

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle_{\mathcal{H}} \\ \text{sujeto a} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C \\ \bullet \text{ Solución: } \mathbf{w} = & \sum_{i=1}^n (\alpha_i y_i) \phi(\mathbf{x}_i) \end{aligned}$$

Problema de optimización

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle_{\mathcal{H}} \\ \text{sujeto a} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C \end{aligned}$$

- Solución: $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \phi(\mathbf{x}_i)$
- Evaluación:

Problema de optimización

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle_{\mathcal{H}} \\ \text{sujeto a} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C \end{aligned}$$

- Solución: $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \phi(\mathbf{x}_i)$
- Evaluación:

$$\text{sign}(\langle \mathbf{w}, \phi(\mathbf{x}) \rangle_{\mathcal{H}} + b)$$

Problema de optimización

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle_{\mathcal{H}} \\ \text{sujeto a} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C \end{aligned}$$

- Solución: $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \phi(\mathbf{x}_i)$
- Evaluación:

$$\text{sign}(\langle \mathbf{w}, \phi(\mathbf{x}) \rangle_{\mathcal{H}} + b) = \text{sign} \left(\sum_{i=1}^n (\alpha_i y_i) \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}) \rangle_{\mathcal{H}} + b \right)$$

Problema de optimización

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle_{\mathcal{H}} \\ \text{sujeto a} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C \end{aligned}$$

- Solución: $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \phi(\mathbf{x}_i)$
- Evaluación:

$$\text{sign}(\langle \mathbf{w}, \phi(\mathbf{x}) \rangle_{\mathcal{H}} + b) = \text{sign} \left(\sum_{i=1}^n (\alpha_i y_i) \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}) \rangle_{\mathcal{H}} + b \right)$$

- Datos sólo aparecen en términos de **productos internos**.

Ejemplo

$$\phi : \mathbb{R}^2 \rightarrow \mathbb{R}^3$$

$$(x_1, x_2) \mapsto (z_1, z_2, z_3) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$$

Ejemplo

$$\phi : \mathbb{R}^2 \rightarrow \mathbb{R}^3$$

$$(x_1, x_2) \mapsto (z_1, z_2, z_3) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$$

