

Otros Algoritmos con Kernels

Fernando Lozano

Universidad de los Andes

31 de octubre de 2022



SVMs

$$\min \quad \frac{1}{2} \|\mathbf{w}\|^2 + \frac{C}{n} \sum_{i=1}^n \zeta_i$$

sujeto a $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$

$$\zeta_i \geq 0$$

SVMs

$$\min \quad \frac{1}{2} \|\mathbf{w}\|^2 + \frac{C}{n} \sum_{i=1}^n \zeta_i$$

$$\text{sujeto a} \quad y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 + \zeta_i \geq 0 \quad i = 1, \dots, n$$
$$\zeta_i \geq 0$$

$$\max \quad \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle$$

$$\text{sujeto a} \quad \sum_{i=1}^n \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq \frac{C}{n}$$

El truco del Kernel

$$\max \quad \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \color{red} k(\mathbf{x}_i, \mathbf{x}_j)$$

sujeto a $\sum_{i=1}^n \alpha_i y_i = 0$

$$0 \leq \alpha_i \leq \frac{C}{n}$$

El truco del Kernel


$$\max \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j k(\mathbf{x}_i, \mathbf{x}_j)$$

sujeto a $\sum_{i=1}^n \alpha_i y_i = 0$

$$0 \leq \alpha_i \leq \frac{C}{n}$$

- Solución: $\mathbf{w} = \sum_{i=1}^n (\alpha_i y_i) \phi(\mathbf{x}_i)$
- Evaluación:

$$\begin{aligned} \text{sign} (\langle w, \phi(\mathbf{x}) \rangle_{\mathcal{H}} + b) &= \text{sign} \left(\sum_{i=1}^n (\alpha_i y_i) \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}) \rangle_{\mathcal{H}} + b \right) \\ &= \text{sign} \left(\sum_{i=1}^n (\alpha_i y_i) k(\mathbf{x}_i, \mathbf{x}) + b \right) \end{aligned}$$



ν -SVM

- C : compromiso entre **márgen** y **error empírico**.

ν -SVM

- C : compromiso entre **márgen** y **error empírico**.
- No es fácil de determinar **a priori**.

ν -SVM

- C : compromiso entre **márgen** y **error empírico**.
- No es fácil de determinar **a priori**.
- No tiene significado intuitivo.

ν -SVM


- C : compromiso entre **márgen** y **error empírico**.
- No es fácil de determinar **a priori**.
- No tiene significado intuitivo.
- ν -SVM reemplaza C por un nuevo parámetro ν que **controla** el número de errores y el número de vectores de soporte:

ν -SVM

- C : compromiso entre **márgen** y **error empírico**.
- No es fácil de determinar **a priori**.
- No tiene significado intuitivo.
- ν -SVM reemplaza C por un nuevo parámetro ν que **controla** el número de errores y el número de vectores de soporte:

$$\min_{\mathbf{w}, b, \zeta_i, \rho} \quad \frac{1}{2} \|\mathbf{w}\|^2 - \nu \rho + \frac{1}{n} \sum_{i=1}^n \zeta_i$$

sujeto a $y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) + \zeta_i - \rho \geq 0 \quad i = 1, \dots, n$
 $\zeta_i \geq 0, \rho \geq 0$



- Lagrangiano ($\delta \geq 0, \zeta \geq 0$):

$$L(\mathbf{w}, b, \zeta, \rho, \alpha, \mu, \delta) = \frac{1}{2} \|\mathbf{w}\|^2 - \nu \rho + \frac{1}{n} \sum_{i=1}^n \zeta_i - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - \rho + \zeta_i) - \sum_{i=1}^n \mu_i \zeta_i - \delta \rho$$

- Lagrangiano ($\delta \geq 0, \zeta \geq 0$):

$$L(\mathbf{w}, b, \zeta, \rho, \alpha, \mu, \delta) = \frac{1}{2} \|\mathbf{w}\|^2 - \nu \rho + \frac{1}{n} \sum_{i=1}^n \zeta_i - \sum_{i=1}^n \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - \rho + \zeta_i) - \sum_{i=1}^n \mu_i \zeta_i - \delta \rho$$

- Derivando con respecto a $\mathbf{w}, b, \zeta, \rho$, e igualando a cero:

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i$$

$$\alpha_i + \mu_i = 1/n$$

$$\sum_{i=1}^n \alpha_i y_i = 0$$

$$\sum_{i=1}^n \alpha_i - \delta = \nu$$

- Problema dual:

$$\max -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{k}(\mathbf{x}_i, \mathbf{x}_j)$$

sujeto a $0 \leq \alpha_i \leq \frac{1}{n}$

$$\sum_{i=1}^n \alpha_i y_i = 0$$

$$\sum_{i=1}^n \alpha_i \geq \nu$$

Propiedades

Propiedades

- Error de márgen: datos que están mal clasificados o tienen margen menor que ρ

Propiedades

- Error de márgen: datos que están mal clasificados o tienen margen menor que ρ (es decir $\zeta_i > 0$).

Propiedades

- Error de márgen: datos que están mal clasificados o tienen margen menor que ρ (es decir $\zeta_i > 0$).
- Si en el óptimo $\rho > 0$, v es una cota superior de el porcentaje de errores de margen.

Propiedades

- Error de márgen: datos que están mal clasificados o tienen margen menor que ρ (es decir $\zeta_i > 0$).
- Si en el óptimo $\rho > 0$, ν es una cota superior de el porcentaje de errores de margen.
 - ▶ Por KKT, $\rho > 0 \Rightarrow \delta = 0$, luego $\sum_{i=1}^n \alpha_i = \nu$,

Propiedades

- Error de márgen: datos que están mal clasificados o tienen margen menor que ρ (es decir $\zeta_i > 0$).
- Si en el óptimo $\rho > 0$, ν es una cota superior de el porcentaje de errores de margen.
 - ▶ Por KKT, $\rho > 0 \Rightarrow \delta = 0$, luego $\sum_{i=1}^n \alpha_i = \nu$, y $\zeta_i > 0 \Rightarrow \alpha_i = 1/n$

Propiedades

- Error de márgen: datos que están mal clasificados o tienen margen menor que ρ (es decir $\zeta_i > 0$).
- Si en el óptimo $\rho > 0$, ν es una cota superior de el porcentaje de errores de margen.
 - ▶ Por KKT, $\rho > 0 \Rightarrow \delta = 0$, luego $\sum_{i=1}^n \alpha_i = \nu$, y $\zeta_i > 0 \Rightarrow \alpha_i = 1/n$
- Si en el óptimo $\rho > 0$, ν es una cota inferior de la fracción de vectores de soporte.

Propiedades

- Error de márgen: datos que están mal clasificados o tienen margen menor que ρ (es decir $\zeta_i > 0$).
- Si en el óptimo $\rho > 0$, ν es una cota superior de el porcentaje de errores de margen.
 - ▶ Por KKT, $\rho > 0 \Rightarrow \delta = 0$, luego $\sum_{i=1}^n \alpha_i = \nu$, y $\zeta_i > 0 \Rightarrow \alpha_i = 1/n$
- Si en el óptimo $\rho > 0$, ν es una cota inferior de la fracción de vectores de soporte.
 - ▶ $\sum_{i=1}^n \alpha_i \geq \nu$,

Propiedades

- Error de márgen: datos que están mal clasificados o tienen margen menor que ρ (es decir $\zeta_i > 0$).
- Si en el óptimo $\rho > 0$, ν es una cota superior de el porcentaje de errores de margen.
 - ▶ Por KKT, $\rho > 0 \Rightarrow \delta = 0$, luego $\sum_{i=1}^n \alpha_i = \nu$, y $\zeta_i > 0 \Rightarrow \alpha_i = 1/n$
- Si en el óptimo $\rho > 0$, ν es una cota inferior de la fracción de vectores de soporte.
 - ▶ $\sum_{i=1}^n \alpha_i \geq \nu$, un vector de soporte tiene $\alpha_i \leq 1/n$.

Propiedades

- Error de márgen: datos que están mal clasificados o tienen margen menor que ρ (es decir $\zeta_i > 0$).
- Si en el óptimo $\rho > 0$, ν es una cota superior de el porcentaje de errores de márgen.
 - ▶ Por KKT, $\rho > 0 \Rightarrow \delta = 0$, luego $\sum_{i=1}^n \alpha_i = \nu$, y $\zeta_i > 0 \Rightarrow \alpha_i = 1/n$
- Si en el óptimo $\rho > 0$, ν es una cota inferior de la fracción de vectores de soporte.
 - ▶ $\sum_{i=1}^n \alpha_i \geq \nu$, un vector de soporte tiene $\alpha_i \leq 1/n$.
- Bajo ciertas condiciones suaves, asimptóticamente con probabilidad 1, ν es igual a la fracción de errores de márgen y a la fracción de vectores de soporte.

Propiedades

- Error de márgen: datos que están mal clasificados o tienen margen menor que ρ (es decir $\zeta_i > 0$).
- Si en el óptimo $\rho > 0$, ν es una cota superior de el porcentaje de errores de márgen.
 - ▶ Por KKT, $\rho > 0 \Rightarrow \delta = 0$, luego $\sum_{i=1}^n \alpha_i = \nu$, y $\zeta_i > 0 \Rightarrow \alpha_i = 1/n$
- Si en el óptimo $\rho > 0$, ν es una cota inferior de la fracción de vectores de soporte.
 - ▶ $\sum_{i=1}^n \alpha_i \geq \nu$, un vector de soporte tiene $\alpha_i \leq 1/n$.
- Bajo ciertas condiciones suaves, asimptóticamente con probabilidad 1, ν es igual a la fracción de errores de márgen y a la fracción de vectores de soporte.
- La solución de ν -SVM con $\rho > 0$, es la misma solución que se obtiene para el SVM con $C = 1/\rho$.

Ejemplo




Figure 7.9 Toy problem (task: separate circles from disks) solved using ν -SV classification, with parameter values ranging from $\nu = 0.1$ (top left) to $\nu = 0.8$ (bottom right). The larger we make ν , the more points are allowed to lie inside the margin (depicted by dotted lines). Results are shown for a Gaussian kernel, $k(x, x') = \exp(-\|x - x'\|^2)$.

ν	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8
fraction of errors	0.00	0.07	0.25	0.32	0.39	0.50	0.61	0.71
fraction of SVs	0.29	0.36	0.43	0.46	0.57	0.68	0.79	0.86
margin $\rho/\ \mathbf{w}\ $	0.005	0.018	0.115	0.156	0.364	0.419	0.461	0.546

Support Vector Regression

- En el problema de regresión queremos aprender una función real $y = f(\mathbf{x})$ a partir de observaciones $\{\mathbf{x}_i, y_i\}_{i=1}^n$.

Support Vector Regression

- En el problema de regresión queremos aprender una función real $y = f(\mathbf{x})$ a partir de observaciones $\{\mathbf{x}_i, y_i\}_{i=1}^n$.
- Criterio de error:

$$R(f) = \mathbf{E}_{z \sim \mathcal{D}} [c(f, \mathbf{x}, y)]$$

Support Vector Regression

- En el problema de regresión queremos aprender una función real $y = f(\mathbf{x})$ a partir de observaciones $\{\mathbf{x}_i, y_i\}_{i=1}^n$.
- Criterio de error:

$$R(f) = \mathbf{E}_{z \sim \mathcal{D}} [c(f, \mathbf{x}, y)]$$

- Por ejemplo:

$$R(f) = \mathbf{E}_{z \sim \mathcal{D}} [(f(\mathbf{x}) - y)^2]$$

Support Vector Regression

- En el problema de regresión queremos aprender una función real $y = f(\mathbf{x})$ a partir de observaciones $\{\mathbf{x}_i, y_i\}_{i=1}^n$.
- Criterio de error:

$$R(f) = \mathbf{E}_{z \sim \mathcal{D}} [c(f, \mathbf{x}, y)]$$

- Por ejemplo:

$$R(f) = \mathbf{E}_{z \sim \mathcal{D}} [(f(\mathbf{x}) - y)^2]$$

- Modelo es una función afín en espacio de características:

Support Vector Regression

- En el problema de regresión queremos aprender una función real $y = f(\mathbf{x})$ a partir de observaciones $\{\mathbf{x}_i, y_i\}_{i=1}^n$.
- Criterio de error:

$$R(f) = \mathbf{E}_{z \sim \mathcal{D}} [c(f, \mathbf{x}, y)]$$

- Por ejemplo:

$$R(f) = \mathbf{E}_{z \sim \mathcal{D}} [(f(\mathbf{x}) - y)^2]$$

- Modelo es una función afín en espacio de características:

$$f(\mathbf{x}) = \langle \mathbf{w}, \mathbf{x} \rangle + b$$

Support Vector Regression

- En el problema de regresión queremos aprender una función real $y = f(\mathbf{x})$ a partir de observaciones $\{\mathbf{x}_i, y_i\}_{i=1}^n$.
- Criterio de error:

$$R(f) = \mathbf{E}_{z \sim \mathcal{D}} [c(f, \mathbf{x}, y)]$$

- Por ejemplo:

$$R(f) = \mathbf{E}_{z \sim \mathcal{D}} [(f(\mathbf{x}) - y)^2]$$

- Modelo es una función afín en espacio de características:

$$f(\mathbf{x}) = \langle \mathbf{w}, \mathbf{x} \rangle + b$$

- Idea: minimizar función de error:

$$\frac{1}{2} \|\mathbf{w}\|^2 + CR_n(f)$$

donde $R_n(f)$ mide error en los datos.

Support Vector Regression

- En el problema de regresión queremos aprender una función real $y = f(\mathbf{x})$ a partir de observaciones $\{\mathbf{x}_i, y_i\}_{i=1}^n$.
- Criterio de error:

$$R(f) = \mathbf{E}_{z \sim \mathcal{D}} [c(f, \mathbf{x}, y)]$$

- Por ejemplo:

$$R(f) = \mathbf{E}_{z \sim \mathcal{D}} [(f(\mathbf{x}) - y)^2]$$

- Modelo es una función afín en espacio de características:


$$f(\mathbf{x}) = \langle \mathbf{w}, \mathbf{x} \rangle + b$$

- Idea: minimizar función de error:

$$\frac{1}{2} \|\mathbf{w}\|^2 + CR_n(f)$$


donde $R_n(f)$ mide error en los datos.

Función de pérdida ϵ -insensitiva



$$|y - f(\mathbf{x})|_{\epsilon} = \max \{0, |y - f(\mathbf{x})| - \epsilon\}$$


Función de pérdida ϵ -insensitiva



$$|y - f(\mathbf{x})|_{\epsilon} = \max \{0, |y - f(\mathbf{x})| - \epsilon\}$$

- Errores dentro del **tubo** no contribuyen al error.


Función de pérdida ϵ -insensitiva




$$|y - f(\mathbf{x})|_{\epsilon} = \max \{0, |y - f(\mathbf{x})| - \epsilon\}$$

- Errores dentro del **tubo** no contribuyen al error.
- En SVMs datos con **margen** no contribuyen al error.

Relación con SVMs




Relación con SVMs



- SVR: $\|w\| \lll$ corresponde a **función plana**.

Relación con SVMs



- SVR: $\|w\| \ll$ corresponde a **función plana**.
- SVM: $\|w\| \ll$ corresponde a **márgen grande**.

ϵ -SVR

$$\min \quad \frac{1}{2} \|\mathbf{w}\|^2 + \frac{C}{n} \sum_{i=1}^n (\zeta_i + \zeta_i^*)$$

$$\begin{aligned} \text{sujeto a } & (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - y_i \leq \epsilon + \zeta_i \\ & y_i - (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \leq \epsilon + \zeta_i^* \\ & \zeta_i, \zeta_i^* \geq 0 \end{aligned}$$

Problema dual

Problema dual

- Lagrangiano ($\alpha, \alpha^*, \eta, \eta^* \geq 0$):

$$L = \frac{1}{2} \|\mathbf{w}\|^2 + \frac{C}{n} \sum_{i=1}^n (\zeta_i + \zeta_i^*) - \sum_{i=1}^n (\eta_i \zeta_i + \eta_i^* \zeta_i^*)$$
$$- \sum_{i=1}^n \alpha_i (\epsilon + \zeta_i + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle - b) - \sum_{i=1}^n \alpha_i^* (\epsilon + \zeta_i^* - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle - b)$$

Problema dual

- Lagrangiano ($\alpha, \alpha^*, \eta, \eta^* \geq 0$):

$$L = \frac{1}{2} \|\mathbf{w}\|^2 + \frac{C}{n} \sum_{i=1}^n (\zeta_i + \zeta_i^*) - \sum_{i=1}^n (\eta_i \zeta_i + \eta_i^* \zeta_i^*) \\ - \sum_{i=1}^n \alpha_i (\epsilon + \zeta_i + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle - b) - \sum_{i=1}^n \alpha_i^* (\epsilon + \zeta_i^* - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle - b)$$

- Derivando con respecto a las variables primales e igualando a cero:

Problema dual

- Lagrangiano ($\alpha, \alpha^*, \eta, \eta^* \geq 0$):

$$L = \frac{1}{2} \|\mathbf{w}\|^2 + \frac{C}{n} \sum_{i=1}^n (\zeta_i + \zeta_i^*) - \sum_{i=1}^n (\eta_i \zeta_i + \eta_i^* \zeta_i^*) \\ - \sum_{i=1}^n \alpha_i (\epsilon + \zeta_i + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle - b) - \sum_{i=1}^n \alpha_i^* (\epsilon + \zeta_i^* - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle - b)$$

- Derivando con respecto a las variables primales e igualando a cero:

$$\sum_{i=1}^n (\alpha_i - \alpha_i^*) = 0$$

Problema dual

- Lagrangiano ($\alpha, \alpha^*, \eta, \eta^* \geq 0$):

$$L = \frac{1}{2} \|\mathbf{w}\|^2 + \frac{C}{n} \sum_{i=1}^n (\zeta_i + \zeta_i^*) - \sum_{i=1}^n (\eta_i \zeta_i + \eta_i^* \zeta_i^*)$$
$$- \sum_{i=1}^n \alpha_i (\epsilon + \zeta_i + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle - b) - \sum_{i=1}^n \alpha_i^* (\epsilon + \zeta_i^* - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle - b)$$

- Derivando con respecto a las variables primales e igualando a cero:

$$\sum_{i=1}^n (\alpha_i - \alpha_i^*) = 0$$

$$\mathbf{w} = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \mathbf{x}_i$$

Problema dual

- Lagrangiano ($\alpha, \alpha^*, \eta, \eta^* \geq 0$):

$$L = \frac{1}{2} \|\mathbf{w}\|^2 + \frac{C}{n} \sum_{i=1}^n (\zeta_i + \zeta_i^*) - \sum_{i=1}^n (\eta_i \zeta_i + \eta_i^* \zeta_i^*) \\ - \sum_{i=1}^n \alpha_i (\epsilon + \zeta_i + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle - b) - \sum_{i=1}^n \alpha_i^* (\epsilon + \zeta_i^* - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle - b)$$

- Derivando con respecto a las variables primales e igualando a cero:

$$\sum_{i=1}^n (\alpha_i - \alpha_i^*) = 0$$

$$\mathbf{w} = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \mathbf{x}_i$$

$$\alpha_i - \eta_i = \alpha_i^* - \eta_i^* = 0$$

Problema Dual

$$\begin{aligned} \text{máx } & -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j) \langle \mathbf{x}_i, \mathbf{x}_j \rangle - \epsilon \sum_{i=1}^n (\alpha_i^* + \alpha_i) \\ & + \sum_{i=1}^n y_i (\alpha_i^* - \alpha_i) \\ \text{sujeto a } & \sum_{i=1}^n (\alpha_i^* - \alpha_i) = 0 \\ & \alpha_i, \alpha_i^* \in [0, C/n] \end{aligned}$$

Problema Dual

$$\begin{aligned} \text{máx} \quad & -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j) \langle \mathbf{x}_i, \mathbf{x}_j \rangle - \epsilon \sum_{i=1}^n (\alpha_i^* + \alpha_i) \\ & + \sum_{i=1}^n y_i (\alpha_i^* - \alpha_i) \\ \text{sujeto a} \quad & \sum_{i=1}^n (\alpha_i^* - \alpha_i) = 0 \\ & \alpha_i, \alpha_i^* \in [0, C/n] \end{aligned}$$

- Datos en términos de productos puntos

Problema Dual

$$\begin{aligned} \text{máx} \quad & -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j) \langle \mathbf{x}_i, \mathbf{x}_j \rangle - \epsilon \sum_{i=1}^n (\alpha_i^* + \alpha_i) \\ & + \sum_{i=1}^n y_i (\alpha_i^* - \alpha_i) \\ \text{sujeto a} \quad & \sum_{i=1}^n (\alpha_i^* - \alpha_i) = 0 \\ & \alpha_i, \alpha_i^* \in [0, C/n] \end{aligned}$$

- Datos en términos de productos puntos \Rightarrow truco del kernel.

KKT

$$① \alpha_i(\epsilon + \zeta_i - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

KKT

- ① $\alpha_i(\epsilon + \zeta_i - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$
- ② $\alpha_i^*(\epsilon + \zeta_i^* + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$

KKT

$$① \quad \alpha_i(\epsilon + \zeta_i - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$② \quad \alpha_i^*(\epsilon + \zeta_i^* + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$③ \quad \left(\frac{C}{n} - \alpha_i \right) \zeta_i = 0$$

KKT

$$\textcircled{1} \quad \alpha_i(\epsilon + \zeta_i - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$\textcircled{2} \quad \alpha_i^*(\epsilon + \zeta_i^* + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$\textcircled{3} \quad \left(\frac{C}{n} - \alpha_i \right) \zeta_i = 0$$

$$\textcircled{4} \quad \left(\frac{C}{n} - \alpha_i^* \right) \zeta_i^* = 0$$

KKT

$$\textcircled{1} \quad \alpha_i(\epsilon + \zeta_i - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$\textcircled{2} \quad \alpha_i^*(\epsilon + \zeta_i^* + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$\textcircled{3} \quad \left(\frac{C}{n} - \alpha_i \right) \zeta_i = 0$$

$$\textcircled{4} \quad \left(\frac{C}{n} - \alpha_i^* \right) \zeta_i^* = 0$$

KKT

$$\textcircled{1} \quad \alpha_i(\epsilon + \zeta_i - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$\textcircled{2} \quad \alpha_i^*(\epsilon + \zeta_i^* + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$\textcircled{3} \quad \left(\frac{C}{n} - \alpha_i \right) \zeta_i = 0$$

$$\textcircled{4} \quad \left(\frac{C}{n} - \alpha_i^* \right) \zeta_i^* = 0$$

Consecuencias:

KKT

$$\textcircled{1} \quad \alpha_i(\epsilon + \zeta_i - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$\textcircled{2} \quad \alpha_i^*(\epsilon + \zeta_i^* + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$\textcircled{3} \quad \left(\frac{C}{n} - \alpha_i \right) \zeta_i = 0$$

$$\textcircled{4} \quad \left(\frac{C}{n} - \alpha_i^* \right) \zeta_i^* = 0$$

Consecuencias:

- Sólo datos para los cuales $\alpha_i = \frac{C}{n}$ o $\alpha_i^* = \frac{C}{n}$ pueden estar fuera del tubo ($\zeta_i > 0$).

KKT

$$① \alpha_i(\epsilon + \zeta_i - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$② \alpha_i^*(\epsilon + \zeta_i^* + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$③ \left(\frac{C}{n} - \alpha_i \right) \zeta_i = 0$$

$$④ \left(\frac{C}{n} - \alpha_i^* \right) \zeta_i^* = 0$$

Consecuencias:

- Sólo datos para los cuales $\alpha_i = \frac{C}{n}$ o $\alpha_i^* = \frac{C}{n}$ pueden estar fuera del tubo ($\zeta_i > 0$).
- $\alpha_i \alpha_i^* = 0$

KKT

$$① \alpha_i(\epsilon + \zeta_i - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$② \alpha_i^*(\epsilon + \zeta_i^* + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$③ \left(\frac{C}{n} - \alpha_i \right) \zeta_i = 0$$

$$④ \left(\frac{C}{n} - \alpha_i^* \right) \zeta_i^* = 0$$

Consecuencias:

- Sólo datos para los cuales $\alpha_i = \frac{C}{n}$ o $\alpha_i^* = \frac{C}{n}$ pueden estar fuera del tubo ($\zeta_i > 0$).
- $\alpha_i \alpha_i^* = 0$
- Para $\alpha_i \in (0, \frac{C}{n})$ (o $\alpha_i^* \in (0, \frac{C}{n})$), podemos calcular:

$$b = y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle - \epsilon$$

KKT

$$① \alpha_i(\epsilon + \zeta_i - y_i + \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$② \alpha_i^*(\epsilon + \zeta_i^* + y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle + b) = 0$$

$$③ \left(\frac{C}{n} - \alpha_i \right) \zeta_i = 0$$

$$④ \left(\frac{C}{n} - \alpha_i^* \right) \zeta_i^* = 0$$

Consecuencias:

- Sólo datos para los cuales $\alpha_i = \frac{C}{n}$ o $\alpha_i^* = \frac{C}{n}$ pueden estar fuera del tubo ($\zeta_i > 0$).
- $\alpha_i \alpha_i^* = 0$
- Para $\alpha_i \in (0, \frac{C}{n})$ (o $\alpha_i^* \in (0, \frac{C}{n})$), podemos calcular:

$$b = y_i - \langle \mathbf{w}, \mathbf{x}_i \rangle - \epsilon$$

- Vectores de soporte son los vectores **fuera del tubo**.

ν -SVR

$$\min \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \left(\nu\epsilon + \frac{1}{n} \sum_{i=1}^n (\zeta_i + \zeta_i^*) \right)$$

$$\text{sujeto a } (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - y_i \leq \epsilon + \zeta_i$$

$$y_i - (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \leq \epsilon + \zeta_i^*$$

$$\zeta_i, \zeta_i^*, \epsilon \geq 0$$

Problema Dual

$$\max -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j) \langle \mathbf{x}_i, \mathbf{x}_j \rangle + \sum_{i=1}^n y_i(\alpha_i^* + \alpha_i)$$

sujeto a $\sum_{i=1}^n (\alpha_i^* - \alpha_i) = 0$

$$\alpha_i, \alpha_i^* \in [0, C/n]$$

$$\sum_{i=1}^n (\alpha_i + \alpha_i^*) \leq C\nu$$

Problema Dual

$$\max -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j) \langle \mathbf{x}_i, \mathbf{x}_j \rangle + \sum_{i=1}^n y_i(\alpha_i^* + \alpha_i)$$

sujeto a $\sum_{i=1}^n (\alpha_i^* - \alpha_i) = 0$

$$\alpha_i, \alpha_i^* \in [0, C/n]$$

$$\sum_{i=1}^n (\alpha_i + \alpha_i^*) \leq C\nu$$

Clasificación de una clase (Detección de anomalías)

Clasificación de una clase (Detección de anomalías)

- Problema: Determinar si un dato x es **típico** de una población.

Clasificación de una clase (Detección de anomalías)

- Problema: Determinar si un dato x es **típico** de una población.
- Detectar el conjunto de soporte de una distribución \mathcal{D} tal que $x \sim \mathcal{D}$.

Clasificación de una clase (Detección de anomalías)

- Problema: Determinar si un dato x es **típico** de una población.
- Detectar el conjunto de soporte de una distribución \mathcal{D} tal que $x \sim \mathcal{D}$.
- Dados datos de entrenamiento $\{x_i\}_{i=1}^n$, queremos encontrar un subconjunto **pequeño** del espacio de entrada que contenga la mayoría de los datos.

Clasificación de una clase (Detección de anomalías)

- Problema: Determinar si un dato x es **típico** de una población.
- Detectar el conjunto de soporte de una distribución \mathcal{D} tal que $x \sim \mathcal{D}$.
- Dados datos de entrenamiento $\{x_i\}_{i=1}^n$, queremos encontrar un subconjunto **pequeño** del espacio de entrada que contenga la mayoría de los datos.
- Clasificador: **1**, adentro de la región, **-1** fuera de la región.

Clasificación de una clase (Detección de anomalías)

- Problema: Determinar si un dato x es **típico** de una población.
- Detectar el conjunto de soporte de una distribución \mathcal{D} tal que $x \sim \mathcal{D}$.
- Dados datos de entrenamiento $\{x_i\}_{i=1}^n$, queremos encontrar un subconjunto **pequeño** del espacio de entrada que contenga la mayoría de los datos.
- Clasificador: **1**, adentro de la región, **-1** fuera de la región.
- Separar datos del origen con un clasificador lineal.

Clasificación de una clase (Detección de anomalías)

- Problema: Determinar si un dato x es **típico** de una población.
- Detectar el conjunto de soporte de una distribución \mathcal{D} tal que $x \sim \mathcal{D}$.
- Dados datos de entrenamiento $\{x_i\}_{i=1}^n$, queremos encontrar un subconjunto **pequeño** del espacio de entrada que contenga la mayoría de los datos.
- Clasificador: **1**, adentro de la región, **-1** fuera de la región.
- Separar datos del origen con un clasificador lineal.
- Kernel: proyección no lineal.

- Problema primal:

$$\min_{\mathbf{w}, \zeta_i, \rho} \quad \frac{1}{2} \|\mathbf{w}\|^2 + \frac{1}{n\nu} \sum_{i=1}^n \zeta_i - \rho$$

sujeto a $\langle \mathbf{w}, \mathbf{x}_i \rangle \geq \rho - \zeta_i \quad i = 1, \dots, n$
 $\zeta_i \geq 0$

- Problema primal:

$$\min_{\mathbf{w}, \zeta_i, \rho} \quad \frac{1}{2} \|\mathbf{w}\|^2 + \frac{1}{n\nu} \sum_{i=1}^n \zeta_i - \rho$$

sujeto a $\langle \mathbf{w}, \mathbf{x}_i \rangle \geq \rho - \zeta_i \quad i = 1, \dots, n$

$$\zeta_i \geq 0$$

- Problema dual:

$$\min \quad \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle$$

sujeto a $0 \leq \alpha_i \leq \frac{1}{\nu n}$

$$\sum_{i=1}^n \alpha_i = 1$$

- Función de decisión (kernelizada):

$$f(x) = \text{sign} \left(\sum_i \alpha_i k(x_i, x) - \rho \right)$$

- Función de decisión (kernelizada):

$$f(x) = \text{sign} \left(\sum_i \alpha_i k(x_i, x) - \rho \right)$$

- Si $\nu \rightarrow 0$, α_i no están acotados, y $\rho \Rightarrow -\infty$.

Kernel PCA

Kernel PCA

- PCA:

$$\mathbf{x} = \sum_{i=1}^L \langle \mathbf{x}, \mathbf{v}_i \rangle \mathbf{v}_i$$

Kernel PCA

- PCA:

$$\mathbf{x} = \sum_{i=1}^L \langle \mathbf{x}, \mathbf{v}_i \rangle \mathbf{v}_i$$

donde $\mathbf{C}\mathbf{v}_i = \lambda_i \mathbf{v}_i$, y

$$\mathbf{C} = \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \mathbf{x}_j^T, \quad \sum_{j=1}^n \mathbf{x}_j = 0, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$$

Kernel PCA

- PCA:

$$\mathbf{x} = \sum_{i=1}^L \langle \mathbf{x}, \mathbf{v}_i \rangle \mathbf{v}_i$$

donde $\mathbf{C}\mathbf{v}_i = \lambda_i \mathbf{v}_i$, y

$$\mathbf{C} = \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \mathbf{x}_j^T, \quad \sum_{j=1}^n \mathbf{x}_j = 0, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$$

- Note que:

$$\lambda_i \mathbf{v}_i = \mathbf{C}\mathbf{v}_i$$

Kernel PCA

- PCA:

$$\mathbf{x} = \sum_{i=1}^L \langle \mathbf{x}, \mathbf{v}_i \rangle \mathbf{v}_i$$

donde $\mathbf{C}\mathbf{v}_i = \lambda_i \mathbf{v}_i$, y

$$\mathbf{C} = \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \mathbf{x}_j^T, \quad \sum_{j=1}^n \mathbf{x}_j = 0, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$$

- Note que:

$$\lambda_i \mathbf{v}_i = \mathbf{C}\mathbf{v}_i = \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \mathbf{x}_j^T \mathbf{v}_i$$

Kernel PCA

- PCA:

$$\mathbf{x} = \sum_{i=1}^L \langle \mathbf{x}, \mathbf{v}_i \rangle \mathbf{v}_i$$

donde $\mathbf{C}\mathbf{v}_i = \lambda_i \mathbf{v}_i$, y

$$\mathbf{C} = \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \mathbf{x}_j^T, \quad \sum_{j=1}^n \mathbf{x}_j = 0, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$$

- Note que:

$$\lambda_i \mathbf{v}_i = \mathbf{C}\mathbf{v}_i = \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \mathbf{x}_j^T \mathbf{v}_i = \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \langle \mathbf{x}_j, \mathbf{v}_i \rangle$$

Kernel PCA

- PCA:

$$\mathbf{x} = \sum_{i=1}^L \langle \mathbf{x}, \mathbf{v}_i \rangle \mathbf{v}_i$$

donde $\mathbf{C}\mathbf{v}_i = \lambda_i \mathbf{v}_i$, y

$$\mathbf{C} = \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \mathbf{x}_j^T, \quad \sum_{j=1}^n \mathbf{x}_j = 0, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$$


- Note que:


$$\lambda_i \mathbf{v}_i = \mathbf{C}\mathbf{v}_i = \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \mathbf{x}_j^T \mathbf{v}_i = \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \langle \mathbf{x}_j, \mathbf{v}_i \rangle$$

Es decir cada $\mathbf{v}_i \in \text{span} \{ \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \}$

- Sistema de ecuaciones:

$$\lambda \langle \mathbf{x}_j, \mathbf{v}_i \rangle = \langle \mathbf{x}_j, \mathbf{Cv}_i \rangle \quad j = 1, \dots, n$$







Estructura de los datos está en **subespacio** de menor dimensión

- Estructura puede ser **no lineal**:

- Estructura puede ser **no lineal**:



- Estructura puede ser **no lineal**:



- Kernel PCA es PCA en espacio de características:

- Kernel PCA es PCA en espacio de características:

$$\mathcal{X} \rightarrow \mathcal{H}$$

$$x \mapsto \phi(x)$$

- Kernel PCA es PCA en espacio de características:

$$\begin{aligned}\mathcal{X} &\rightarrow \mathcal{H} \\ x &\mapsto \phi(x)\end{aligned}$$

- Suponemos datos centrados:

$$\sum_{i=1}^n \phi(x_i) = 0$$

- Kernel PCA es PCA en espacio de características:

$$\begin{aligned}\mathcal{X} &\rightarrow \mathcal{H} \\ x &\mapsto \phi(x)\end{aligned}$$

- Suponemos datos centrados:

$$\sum_{i=1}^n \phi(x_i) = 0$$

- Consideramos matriz de covarianza:

$$\mathbf{C} = \frac{1}{n} \sum_{i=1}^n \phi(x_i) \phi(x_i)^T$$

- Kernel PCA es PCA en espacio de características:

$$\begin{aligned}\mathcal{X} &\rightarrow \mathcal{H} \\ x &\mapsto \phi(x)\end{aligned}$$

- Suponemos datos centrados:

$$\sum_{i=1}^n \phi(x_i) = 0$$

- Consideramos matriz de covarianza:

$$\mathbf{C} = \frac{1}{n} \sum_{i=1}^n \phi(x_i) \phi(x_i)^T$$

- Si $\dim(\mathcal{H}) = \infty$, $\phi(x_i) \phi(x_i)^T$ corresponde a operador lineal en \mathcal{H} :

$$x \mapsto \phi(x_i) \langle \phi(x_i), x \rangle_{\mathcal{H}}$$

- Queremos encontrar valores y vectores propios:

$$\lambda \mathbf{v} = \mathbf{C}\mathbf{v}$$

- Queremos encontrar valores y vectores propios:

$$\lambda \mathbf{v} = \mathbf{C}\mathbf{v}$$

- Ecuaciones:

- Queremos encontrar valores y vectores propios:

$$\lambda \mathbf{v} = \mathbf{Cv}$$

- Ecuaciones:

$$\lambda \langle \phi(x_j), \mathbf{v} \rangle_{\mathcal{H}} = \langle \phi(x_j), \mathbf{Cv} \rangle_{\mathcal{H}} \quad j = 1, \dots, n$$

- Queremos encontrar valores y vectores propios:

$$\lambda \mathbf{v} = \mathbf{Cv}$$

- Ecuaciones:

$$\lambda \langle \phi(x_j), \mathbf{v} \rangle_{\mathcal{H}} = \langle \phi(x_j), \mathbf{Cv} \rangle_{\mathcal{H}} \quad j = 1, \dots, n$$

$$\mathbf{v} = \sum_{i=1}^n \alpha_i \phi(x_i)$$

- Queremos encontrar valores y vectores propios:

$$\lambda \mathbf{v} = \mathbf{C}\mathbf{v}$$

- Ecuaciones:

$$\lambda \langle \phi(x_j), \mathbf{v} \rangle_{\mathcal{H}} = \langle \phi(x_j), \mathbf{C}\mathbf{v} \rangle_{\mathcal{H}} \quad j = 1, \dots, n$$

$$\mathbf{v} = \sum_{i=1}^n \alpha_i \phi(x_i)$$

- Combinando:

$$\lambda \sum_{i=1}^n \alpha_i \langle \phi(x_j), \phi(x_i) \rangle_{\mathcal{H}} =$$

$$\frac{1}{n} \sum_{i=1}^n \alpha_i \left\langle \phi(x_j), \sum_{j=1}^n \phi(x_j) \langle \phi(x_j), \phi(x_i) \rangle_{\mathcal{H}} \right\rangle_{\mathcal{H}}$$

para $j = 1, \dots, n$

- En términos de la matriz de Gramm, es equivalente a:

$$n\lambda \mathbf{K}\boldsymbol{\alpha} = \mathbf{K}^2\boldsymbol{\alpha}$$

- En términos de la matriz de Gramm, es equivalente a:

$$n\lambda \mathbf{K}\boldsymbol{\alpha} = \mathbf{K}^2\boldsymbol{\alpha}$$

cuyas soluciones se pueden encontrar resolviendo:

$$n\lambda \boldsymbol{\alpha} = \mathbf{K}\boldsymbol{\alpha}$$

- En términos de la matriz de Gramm, es equivalente a:

$$n\lambda \mathbf{K}\boldsymbol{\alpha} = \mathbf{K}^2\boldsymbol{\alpha}$$

cuyas soluciones se pueden encontrar resolviendo:

$$n\lambda \boldsymbol{\alpha} = \mathbf{K}\boldsymbol{\alpha}$$

- Normalización $\|\mathbf{v}\|_{\mathcal{H}} = 1$:

- En términos de la matriz de Gramm, es equivalente a:

$$n\lambda \mathbf{K}\boldsymbol{\alpha} = \mathbf{K}^2\boldsymbol{\alpha}$$

cuyas soluciones se pueden encontrar resolviendo:

$$n\lambda \boldsymbol{\alpha} = \mathbf{K}\boldsymbol{\alpha}$$

- Normalización $\|\mathbf{v}\|_{\mathcal{H}} = 1$:

$$1 = \sum_{i=1}^n \sum_{j=1}^n \alpha_i, \alpha_j \langle \phi(x_j), \phi(x_i) \rangle$$

- En términos de la matriz de Gramm, es equivalente a:

$$n\lambda \mathbf{K}\boldsymbol{\alpha} = \mathbf{K}^2\boldsymbol{\alpha}$$

cuyas soluciones se pueden encontrar resolviendo:

$$n\lambda \boldsymbol{\alpha} = \mathbf{K}\boldsymbol{\alpha}$$

- Normalización $\|\mathbf{v}\|_{\mathcal{H}} = 1$:

$$1 = \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \langle \phi(x_j), \phi(x_i) \rangle = \langle \boldsymbol{\alpha}, \mathbf{K}\boldsymbol{\alpha} \rangle$$

- En términos de la matriz de Gramm, es equivalente a:

$$n\lambda \mathbf{K}\boldsymbol{\alpha} = \mathbf{K}^2\boldsymbol{\alpha}$$

cuyas soluciones se pueden encontrar resolviendo:

$$n\lambda \boldsymbol{\alpha} = \mathbf{K}\boldsymbol{\alpha}$$

- Normalización $\|\mathbf{v}\|_{\mathcal{H}} = 1$:

$$1 = \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \langle \phi(x_j), \phi(x_i) \rangle = \langle \boldsymbol{\alpha}, \mathbf{K}\boldsymbol{\alpha} \rangle = \lambda \langle \boldsymbol{\alpha}, \boldsymbol{\alpha} \rangle$$

- En términos de la matriz de Gramm, es equivalente a:

$$n\lambda \mathbf{K}\boldsymbol{\alpha} = \mathbf{K}^2\boldsymbol{\alpha}$$

cuyas soluciones se pueden encontrar resolviendo:

$$n\lambda \boldsymbol{\alpha} = \mathbf{K}\boldsymbol{\alpha}$$

- Normalización $\|\mathbf{v}\|_{\mathcal{H}} = 1$:

$$1 = \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \langle \phi(x_j), \phi(x_i) \rangle = \langle \boldsymbol{\alpha}, \mathbf{K}\boldsymbol{\alpha} \rangle = \lambda \langle \boldsymbol{\alpha}, \boldsymbol{\alpha} \rangle$$

- Para un nuevo dato x :

- En términos de la matriz de Gramm, es equivalente a:

$$n\lambda \mathbf{K}\boldsymbol{\alpha} = \mathbf{K}^2\boldsymbol{\alpha}$$

cuyas soluciones se pueden encontrar resolviendo:

$$n\lambda \boldsymbol{\alpha} = \mathbf{K}\boldsymbol{\alpha}$$

- Normalización $\|\mathbf{v}\|_{\mathcal{H}} = 1$:

$$1 = \sum_{i=1}^n \sum_{j=1}^n \alpha_i, \alpha_j \langle \phi(x_j), \phi(x_i) \rangle = \langle \boldsymbol{\alpha}, \mathbf{K}\boldsymbol{\alpha} \rangle = \lambda \langle \boldsymbol{\alpha}, \boldsymbol{\alpha} \rangle$$

- Para un nuevo dato x :

$$\langle \mathbf{v}, \phi(x) \rangle_{\mathcal{H}}$$

- En términos de la matriz de Gramm, es equivalente a:

$$n\lambda \mathbf{K}\boldsymbol{\alpha} = \mathbf{K}^2\boldsymbol{\alpha}$$

cuyas soluciones se pueden encontrar resolviendo:

$$n\lambda \boldsymbol{\alpha} = \mathbf{K}\boldsymbol{\alpha}$$

- Normalización $\|\mathbf{v}\|_{\mathcal{H}} = 1$:

$$1 = \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \langle \phi(x_j), \phi(x_i) \rangle = \langle \boldsymbol{\alpha}, \mathbf{K}\boldsymbol{\alpha} \rangle = \lambda \langle \boldsymbol{\alpha}, \boldsymbol{\alpha} \rangle$$

- Para un nuevo dato x :

$$\langle \mathbf{v}, \phi(x) \rangle_{\mathcal{H}} = \sum_{i=1}^n \alpha_i \langle \phi(x_i), \phi(x) \rangle_{\mathcal{H}}$$

- En términos de la matriz de Gramm, es equivalente a:

$$n\lambda \mathbf{K}\boldsymbol{\alpha} = \mathbf{K}^2\boldsymbol{\alpha}$$

cuyas soluciones se pueden encontrar resolviendo:

$$n\lambda \boldsymbol{\alpha} = \mathbf{K}\boldsymbol{\alpha}$$

- Normalización $\|\mathbf{v}\|_{\mathcal{H}} = 1$:

$$1 = \sum_{i=1}^n \sum_{j=1}^n \alpha_i, \alpha_j \langle \phi(x_j), \phi(x_i) \rangle = \langle \boldsymbol{\alpha}, \mathbf{K}\boldsymbol{\alpha} \rangle = \lambda \langle \boldsymbol{\alpha}, \boldsymbol{\alpha} \rangle$$

- Para un nuevo dato x :

$$\langle \mathbf{v}, \phi(x) \rangle_{\mathcal{H}} = \sum_{i=1}^n \alpha_i \langle \phi(x_i), \phi(x) \rangle_{\mathcal{H}} = \sum_{i=1}^n \alpha_i k(x_i, x)$$

- Para obtener PCA con datos centrados en \mathcal{H} , reemplazanos \mathbf{K} por:

$$\tilde{\mathbf{K}} = \mathbf{K} - \mathbf{J}\mathbf{K} - \mathbf{K}\mathbf{J} + \mathbf{J}\mathbf{K}\mathbf{J}$$

donde $[\mathbf{J}]_{ij} = \frac{1}{n}, \forall i, j$